

# Pokemon Battle Predictor - Report

Alessandro Gautieri

gautieri.2041850@studenti.uniroma1.it

Tommaso Federici

federici.2214368@studenti.uniroma1.it

Lorenzo Colombini

colombini.1973692@studenti.uniroma1.it

## Abstract

*Sistema di predizione per battaglie Pokémon competitive basato su ensemble di gradient boosting models (LightGBM, CatBoost, XGBoost). L'architettura combina feature engineering avanzata (numerosi features multi-scala temporali, predizione tipi non visti, interaction features) con strategie di training robuste (10-fold CV, side-swap augmentation, isotonic calibration). L'ottimizzazione Bayesiana parallela degli iperparametri e il weighted averaging ensemble garantiscono generalizzazione ottimale. Performance finale: 84.71% accuracy, 92.14% AUC, 0.355 LogLoss.*

## 1. Feature Engineering (339 features)

### 1.1. Finestre Temporali Multi-Scala

Il battle log viene segmentato in tre finestre (w1: turni 1–10, w2: 11–20, w3: 21–30) per catturare dinamiche early/mid/late game. Per ogni finestra tracciamo:

- **Damage dealt/taken:** pressione offensiva per fase
- **KO e switches:** momentum e controllo del match
- **Status afflictions:** debuff strategici
- **Super-effective hits:** sfruttamento matchup tipo

Questo approccio permette al modello di distinguere strategie aggressive early-game da comebacks nel late-game.

### 1.2. Predizione Tipi Non Visti dell'Avversario

Innovazione chiave: prediciamo i tipi dei Pokémon non ancora rivelati usando la distribuzione globale dei tipi (da `predict.csv`). Calcoliamo il **vantaggio di tipo atteso** moltiplicando le probabilità dei tipi non visti per i moltiplicatori offensivi del nostro team. La feature `p1_expected_type_advantage_unseen_p2` cattura il potenziale strategico contro Pokémon nascosti. Questo è possibile sapendo che il dataset è composto da battaglie reali usando i primi 151 pokemon, poiché le battaglie in tornei ufficiali hanno una distribuzione tipica dei tipi nei team.

## 1.3. Feature Chiave Aggiuntive

- **Type Coverage Metrics:** super-effective/immune/resist counts per team, identificano punti deboli strutturali
- **Offensive/Defensive Ratio:**  $(Atk + SpA) / (HP + Def + SpD)$  misura bilanciamento team
- **HP Trajectory:** `avg_hp_pct_start`, `avg_hp_pct_end`, `delta` quantificano trade efficiency
- **Interaction Features:** prodotti non-lineari tra feature correlate (es. `damage × speed`, `status × HP_advantage`) che i GBDT non scoprono facilmente da soli

## 2. Training Strategy

### 2.1. Ensemble Architecture

Tre gradient boosting models complementari:

- **LightGBM** (peso 0.431): veloce, ottimo su feature numeriche, gestisce class imbalance con `class_weight='balanced'`
- **CatBoost** (peso 0.284): robusto su feature categoriche, riduce overfitting
- **XGBoost** (peso 0.284): regolarizzazione L1/L2 forte, stabilità predittiva

### 2.2. Cross-Validation e Augmentation

- **10-fold Stratified CV:** preserva distribuzione classi (50/50)
- **Side-Swap Augmentation:** raddoppia il training set invertendo prospettiva P1P2 (matchup speculare con label invertito)
- **Seed Bagging** (3 seeds): media predizioni con seed diversi per ridurre varianza
- **Isotonic Calibration:** per-fold e finale, migliora probabilità calibrate

### 2.3. Ensemble Method: Weighted Average

Grid search su OOF predictions identifica pesi ottimali (0.431, 0.284, 0.284). Superiore a stacking poiché più robusto e generalizza meglio su test set (0.84710 vs 0.84480).